

Identification of Hub Genes in the Proteomics Network of Long COVID

Science and Data Visualization in Healthcare - 1s2026

<https://github.com/ElementsMO430Unicamp/ProjectsMO430>

Carlos Vinícius Araki Oliveira

Carlos Eduardo Rosa Luengo

Sabrina Tomaz Barbosa

Luisa Freitas Colafati

Maria Vitória Barbosa Valladares

Muhammad Zuhair

Mary Cristina Hernandez Xavier

1

Pesquisa

Problema e abordagem

O Labirinto da **Long COVID**: O Impacto da Inflamação no Cérebro e no Corpo

Uma condição multissistêmica impulsionada por inflamação persistente que afeta severamente as funções cognitivas e vasculares.

CÉREBRO




O Fenômeno da “Névoa Cerebral”

Caracteriza-se por prejuízo cognitivo, déficits de memória e dificuldades de concentração resultantes do envolvimento do sistema nervoso central.



Ruptura da Barreira Hematoencefálica

A inflamação crônica pode comprometer a proteção do cérebro, permitindo a entrada de substâncias nocivas e mantendo a neuroinflamação.



CORPO



Inflamação Sistêmica Ininterrupta

Marcadores inflamatórios e citocinas (como IL-17 e TNF- α) permanecem elevados por até 2 anos, mantendo o corpo em estado de alerta máximo.



Disfunção Vascular e Microcoágulos

Danos no endotélio e a presença de microcoágulos dificultam a circulação e o transporte de oxigênio para os tecidos.



Falha Energética e Fadiga Crônica

A disfunção das mitocôndrias impede a produção adequada de energia celular, assemelhando-se à síndrome de fadiga crônica (ME/CFS).

2

Dados

Origens e conexões

Mapa das Bases (Origem, Tipo e Papel)



GEO/NIH (Gene Expression Omnibus)

Tipo: Expressão Gênica/Transcriptômica Pública.

Fonte: Arquivos CSV locais (Ex: GSE251849, GSE275334, NOS0001).

Papel: Fonte principal de genes com sinal diferencial.



EBI Expression Atlas

Tipo: Expressão Gênica Comparativa por Experimento.

Fonte: APIs e Downloads (ebi.ac.uk/gxa/...).

Papel: Complementar evidências de expressão (Homo sapiens).



STRING DB

Tipo: Banco de Interações Proteína-Proteína (PPI).

Fonte: API (string-db.org/api/json).

Papel: Transformar lista de genes em rede de interações e scores.

Campos Principais Extraídos

GEO/NIH

ID do Gene	Valor de Expressão	P-valor	Fold Change
------------	--------------------	---------	-------------

EBI Expression Atlas

experiment_ _accession	gene_id	gene_ _name	comparison_ _label	expression_ _value
---------------------------	---------	----------------	-----------------------	-----------------------

STRING DB

string IDs	preferred names	combined_ _score	Evidências de Interação
---------------	--------------------	---------------------	----------------------------


Conexão entre Bases (Fluxo de Integração)



GEO/NIH




EBI Expression Atlas



Genes e Dados de Expressão



STRING DB



Rede de Interações com Scores



Priorização de Candidatos

Objetivo Científico: Integrar expressão gênica (GEO + EBI) com conectividade de rede (STRING) para possibilitar a priorização de genes/proteínas centrais em Long COVID.

Contribuição de Cada Base para Long COVID



GEO/NIH: Sinal diferencial em datasets clínicos.



EBI Expression Atlas: Robustez e complemento entre experimentos.



STRING DB: Contexto de interação biológica (hub potencial).

Legenda: GEO: Gene Expression Omnibus; EBI: European Bioinformatics Institute; PPI: Protein-Protein Interaction; API: Application Programming Interface.

3

Workflow


Apache Airflow

Apache Airflow

- Ferramenta open source para orquestração de pipelines de dados
- Orquestração por meio de **grafos acíclicos direcionados (DAGs)**
- Workflows criados com **Python scripts**
- Componentes:
 - **airflow-scheduler** - monitora todas as tarefas e DAGs uma vez que as dependências são completadas
 - **airflow-worker** - executa tarefas com possibilidade de escalonamento em várias instâncias da rede
 - **airflow-webserver** - interface gráfica para interagir com o Apache Airflow



Arquitetura Medalhão





FONTES DE DADOS E APIs

GEO/NIH (Dados Transcriptômicos)



GEO/NIH

Arquivos CSV locais
(Datasets: GSE251849,
GSE275334, NOS0001)

Obs: Entrada via CSV local,
não API ativa.

EBI Expression Atlas (API)



API
EBI
Expression
Atlas

EBI Search API
(<https://www.ebi.ac.uk/ebisearch/ws/rest/atlas-experiments>)

GXA metadata API
(<https://www.ebi.ac.uk/gxa/json/experiments/{accession}>)

Download de matriz
(<https://www.ebi.ac.uk/gxa/...>)

STRING DB API (PPI)



API
STRING DB
API

Base:
<https://string-db.org/api/json>

Endpoints:
/get_string_ids e /network

Parâmetros-chave:
species=9606 (Homo sapiens),
required_score=400

Integração multi-fonte:
GEO/NIH + EBI + STRING



BRONZE LAYER

Ingestão
GEO local



data/bronze/bronze_*.csv
(Ex: bronze_GSE*.csv,
bronze_NOS*.csv)

Ingestão
EBI



bronze_ebi_expression.csv



Função: Preservar dado
bruto + rastreabilidade
(ingested_at).
Saídas: Arquivos brutos
imutáveis.

CRITÉRIO DE PRIORIZAÇÃO DE HUB GENES

- ✓ Alta eigenvector centrality.
- ✓ Expressão diferencial relevante ($|\log_2FC|$ alto + padj significativo).
- ✓ Suporte de interação robusta (combined_score STRING).



SILVER LAYER

Transformação 1: silver_geo_nodes

Limpeza/padronização de
GEO por gene

Transformação 2: silver_geo_nodes_principal

Filtra genes principais,
remove descrições inválidas,
uncharacterized/tRNA

Transformação 3: silver_ebi_nodes

Limpeza EBI, deduplicação,
conversão numérica de
expression_value_numeric



DESAFIO CLÍNICO

Metadados clínicos
heterogêneos no NIH/GEO
(campos textuais/sinônimos).
Harmonização de campos
clínicos no preprocessing.



GOLD LAYER



gold_geo_nodes.csv
Join por geneid.

Atributos: symbol, geneid,
 $\log_2foldchange$, padj,
descrição.

Integração
PPI



gold_edge_ppi.csv

- STRING resolve IDs e consulta interações PPI
- Scores: experimentally_determined_inte raction, database_annotated, automated_textmining, combined_score.
- Deduplicação de arestas.



SAÍDA DE CONHECIMENTO

Resultado esperado: identificação de
proteínas centrais e diferencialmente
expressas, potencialmente associadas a
mecanismos de inflamação persistente e
disfunção em Long COVID.



ANÁLISE FINAL NO CYTOSCAPE

Importar
como
EDGES



Calcular Centralidades
(Destaque: Eigenvector
Centrality)

Integrar Centralidade
+ Expressão Gênica
($\log_2FC$ /padj)

Importar
como
NODE
ATTRIBUTES



Hub Gene


**Priorizar Hub Genes/Proteínas
Candidatas com Potencial Impacto
em Long COVID**

Aplicação: hipóteses biológicas
para Long COVID

Bronze: Ingestão/Bruto (#CD7F32)
Silver: Limpeza/Transformação (#A8A9AD)
Gold: Consolidação/Integração (#D4AF37)
Análise/Cytoscape: Identificação de Hubs (#2B)

Interface gráfica do workflow


- ▼ dags
 - ▼ medallion
 - > bronze
 - > gold
 - > silver
 - > utils
 - 📄 .airflowignore
 - 📄 medallion_pipeline_dag.py
- ▼ data
 - > bronze
 - > gold
 - > raw
 - > silver




4

Análise de Dados

Cytoscape




All network



All network - GEO dataset GSE251849

- Rede com 5149 nós e 4653 arestas
- Filtros utilizados :
 - p-Value < 0.05
 - Fold Change > 1
 - Retirada de dados de Brain Fog (Percebemos que isso dificultava o quadro de visualização de inflamação)

Eigenvector



Result 1 ▾

Result List(114 in total)

☐ Sorting in select nodes
 ☒ Sorting in whole network

No.	Name	Eigenvector
1	IL1B	0.4038297235965729
2	ICAM1	0.38380739092826843
3	EGF	0.3760266900062561
4	SELP	0.32025718688964844
5	PF4	0.2882958948612213
6	TNFAIP6	0.2730952799320221
7	CXCL5	0.23267784714698792
8	PTX3	0.20490628480911255
9	ICFBP2	0.17967356741428375
10	OSM	0.15277737379074097
11	SNAI1	0.14568033814430237
12	CLEC1B	0.1426418125629425
13	SMAD7	0.13503234088420868
14	SPARC	0.12364334613084793
15	BCL3	0.10341244919093132
16	NAMPT	0.10341235250234604
17	BMP6	0.10295110195875168
18	FCAM	0.00245474636554718

Select by rank

Top Proteins

Select

Top % Proteins

Select

Select by value

Eigenvector


☒ Max
 ☐ 38.
 ☐ ~
 ☐ Min
 ☐ 0.1

Select

Export

Value Distribution

Eigenvector Maior Subnet- 5 candidatos promissores



. IL1B
. ICAM1
. EGF
. SELP
. PF4...

Result 1 ▾

Result List(114 in total)

☐ Sorting in select nodes ☒ Sorting in whole netw

No.	Name	Eigenvector
1	IL1B	0.4038297235965729
2	ICAM1	0.38380739092826843
3	EGF	0.3760266900062561
4	SELP	0.32025718688964844
5	PF4	0.2882958948612213
6	TNFAIP6	0.2730952799320221
7	CXCL5	0.23267784714698792
8	PTX3	0.20490628480911255
9	IGFBP2	0.17967356741428375
10	OSM	0.15277737379074097
11	SNAI1	0.14568033814430237
12	CLEC1B	0.1426418125629425
13	SMAD7	0.13503234088420868
14	SPARC	0.12364334613084793
15	BCL3	0.1034124419093132
16	NAMPT	0.10341235250234604
17	BMP6	0.10295110195875168
18	ESAM	0.09345474626554718


Select by rank

Top Proteins Top % Proteins

Select by value

Eigenvector ▾ Max 38. ~ Min 0.1

Expression + Eigenvector - 5 candidatos promissores



- . IL1B ↓
- . ICAM1 ↓
- . EGF ↑
- . SELP ↑
- . PF4 ↑

For the analysis = Log2 FC




log2foldchange
3.12859
2.45864
2.31685
2.10557
2.07614
2.03507

5

Pathway + Differential Expression

Pathway





FONTES DE DADOS E APIS

GEO/NIH (Dados Transcriptômicos)

Arquivos CSV locais
(Datasets: GSE251849, GSE275334, N050001)
Obs: Entrada via CSV local, aba API ativa.

EBI Expression Atlas (API)

EBI Search API
(<https://www.ebi.ac.uk/ebisearch/ci/whs/rest/atlas-experiments>)
GXA metadata API
(<https://www.ebi.ac.uk/gxa/json/experiments/accession>)
Download de matriz
(<https://www.ebi.ac.uk/gxa/...>)

STRING DB API (PPI)

Base:
<https://string.db.org/api/json>
Endpoints:
[/get_string_ids_e/network](https://string.db.org/api/json/get_string_ids_e/network)
Parâmetros-chave:
species=9605 (Homo sapiens), required_score=400

Integração multi-fonte:
GEO/NIH + EBI + STRING



BRONZE LAYER

Ingestão
GEO local

data/bronze/bronze_*.csv
(Ex: bronze, SSE*.csv, bronze_NOS*.csv)

Ingestão
EBI

bronze_ebi_expression.csv



Função: Preservar dado bruto + rastreabilidade (ingested_at).
Saídas: Arquivos brutos imutáveis.



SILVER LAYER

Transformação 1:
silver_geo_nodes
Limpeza/padronização de GEO por gene

Transformação 2:
silver_geo_nodes_principal
Filtra genes principais, remove descrições inválidas, uncharacterized/tRNA

Transformação 3:
silver_ebi_nodes
Limpeza EBI, deduplicação, conversão numérica de expression_value_numeric



DESAFIO CLÍNICO

Metadados clínicos heterogêneos no NIH/GEO (campos textuais/sinônimos).
Homonização de campos clínicos no preprocessing.

CRITÉRIO DE PRIORIZAÇÃO DE HUB GENES

- ✓ Alta eigenvector centrality.
- ✓ Expressão diferencial relevante (llog2FC) alto + padj significativo).
- ✓ Suporte de interação robusta (combined_score STRING).



GOLD LAYER

gold_geo_nodes.csv
Join por geneid.
Atributos: symbol, geneid, log2foldchange, padj, descrição.

Integração
PPI

gold_edge_ppi.csv

- STRING resolve IDs e consulta interações PPI
- **Scores:** experimentally_determined, interaction, database, annotated, automated, textmining, combined_score.
- Deduplicação de arestas.

SAÍDA DE CONHECIMENTO




Resultado esperado: identificação de proteínas centrais e diferencialmente expressas, potencialmente associadas a mecanismos de inflamação persistente e disfunção em Long COVID.



ANÁLISE FINAL NO CYTOSCAPE

Importar
como
EDGES



Calcular Centralidades
(Destaque: Eigenvector Centrality)

Integrar Centralidade + Expressão Gênica
(log2FC/padj)



Visualização na Vercel da Pathway no KEGG


Vercel

Aplicação de visualização a partir da expressão gênica


• **Processo:** Mapeamento de genes-chave (hubs) em vias KEGG

• **Exemplos:** Vias de mas de inflamação, via de sinalização de TNF, etc.

• **Objetivo:** Visualização interativa do impacto biológico



Expression + Pathway




Tente você!



<https://long-covid-expression-geo.vercel.app/>

Expression + Pathway




<https://long-covid-expression-geo.vercel.app/>

6

Exploratória

SLM Focado na semântica médica





FONTES DE DADOS E APIS

GEO/NIH (Dados Transcriptômicos)



Arquivos CSV locais
(Datasets: GSE251849,
GSE275334, N050001)
Obs: Entrada via CSV local,
aba AFI ativa.

EBI Expression Atlas (API)



EBI Search API
(<https://www.ebi.ac.uk/ebisearch/clows/roast/alias/experiments>)
GXA metadata API
(<https://www.ebi.ac.uk/gxa/json/experiments/Zcaccessiont>)
Download de matriz
(<https://www.sbl.ac.uk/gxa/...>)

STRING DB API (PPI)



Base:
<https://string.db.org/api/json>
Endpoints:
[/get_string_ids.e /network](#)
Parâmetros-chave:
species=9605 (Homo aspiens),
required_score=400

Integração multi-fonte:
GEO/NIH + EBI + STRING



BRONZE LAYER

Ingestão
GEO local



data/bronze/bronze_*.csv
(Ex. bronze_SSE*.csv,
bronze_NOS*.csv)

Ingestão
EBI



bronze_ebi_expression.csv



Função: Preservar dado
bruto + rastreabilidade
(ingested_at).
Saídas: Arquivos brutos
imutáveis.



SILVER LAYER

Transformação 1:
silver_geo_nodes

Limpeza/padronização de
GEO por gene

Transformação 2:
silver_geo_nodes_principal

Filtra genes principais,
remove descrições inválidas,
uncharacterized/IRNA

OLLAMA PARA
PROCESSAMENTO EXTERNO SLM

Small Language
Model (SLM)



Modelo:
MedAlBase/MedGemma1.5:4b

Vincular Sintoma -> Gene

Utiliza o SLM para mapear e
vincular dados de expressão e
ontologias clínicas.



GOLD LAYER



gold_geo_nodes.csv

Join por geneid.
Antbotos. symbol, geneid,
log2foldchange, padj,
descrição.



Integração
PPI

gold_edge_ppi.csv

- STRING resolve ItIs e consulta
interações PPI
- Scores:
experimentally_determined_inte
reccion, database. annotated,
automated, textmining,
combined_score.
- Deduplicação de arestas.



ANÁLISE FINAL NO CYTOSCAPE

Importar
como
EDGES



Calcular Contralidades
(Destaque: Eigenvector
Centrality)

Integrar Centralidade
+ Expressão Gênica
(log2FC/padj)



**Visualização na Vercel
da Pathway no KEGG**




**Aplicação de visualização
a partir de expressão
gênica**

- **Processo:**
Mapeamento
de genes-chave
(hubs) em vias
KEGG

- **Exemplos:**
Vias de mas de
inflamação, via de
sinalização
de TNF, etc.

- **Objetivo:**
Visualização interativa do impacto biológico



CRITÉRIO DE PRIORIZAÇÃO DE HUB GENES

- ✓ Alta eigenvector centrality.
- ✓ Expressão diferencial relevante (log2FC) alto + padj significativo).
- ✓ Suporte de interação robusta (combined_score STRING).



SAÍDA DE CONHECIMENTO

Resultado esperado: identificação de proteínas centrais e diferencialmente expressas, potencialmente associadas a mecanismos de inflamação persistente e disfunção em Long COVID.

Dificuldades encontradas


1. Erros 500 (Internal Server Error) ao chamar API do Ollama
2. Tempo de processamento
3. Alucinação em escopos maiores (donde surgiu a necessidade de RAG)
4. Recursos de hardware: Com um computador de 16 GB ram e 7 CPUs, não foi possível executar Airflow e Ollama localmente em paralelo

```
[7/278] Classificando IGFBP2...
[8/278] Classificando CCR8...
[9/278] Classificando C2orf88...
[10/278] Classificando LINC00892...
[11/278] Classificando NAT8B...
[12/278] Classificando THRB-AS2...
[13/278] Classificando CA2...
[14/278] Classificando LINC00989...
[15/278] Classificando RAB27B...
[16/278] Classificando SNAI1...
[-] Erro em SNAI1: 500 Server Error: Internal Server Error for url: http://localhost:11434/api/generate
[17/278] Classificando PIF1...
[18/278] Classificando CLSTN3...
[19/278] Classificando TSC22D1...
[20/278] Classificando IGLV3-27...
[21/278] Classificando IGLV2-5...
[22/278] Classificando RNF5P1...
[23/278] Classificando PTGS2...
[24/278] Classificando ABCC3...
[25/278] Classificando H3C10...
[26/278] Classificando IGHV3-9...
[27/278] Classificando TPX2...
```


Resultados

Nível de confiança da classificação


Erro
8,6%
Baixa
1,4%
Alta
10,1%



- Alta > 90%
- Média > 80%
- Baixa < 80 %

Média
79,9%

Ocorrência de sintomas na classificação




Gene	Sintomas classificados	Confiança da classificação
IL1B	fadiga; cefaleia; dispneia; tosse; mialgia; artralgia; ansiedade; depressão; insônia; distúrbios do sono; inflamação; disfunção autonômica; hipoxemia; dor torácica; distúrbios gastrointestinais; perda de apetite; náusea; vômito; diarreia; rash cutâneo; perda de cabelo; neuropatia periférica; tontura; anosmia; disgeusia; brain fog; palpitações; febre	Alta > 90 %
ICAM1	fadiga; brain fog	Média > 80%
EGF	fadiga; brain fog	Média > 80%
SELP	Erro	Erro
PF4	inflamação; disfunção autonômica	Média > 80%

Artigos - Validação e Hipóteses

IL-1 β Levels

Only marker consistently elevated
No normalization over 9 months
Sustained low-grade inflammation




1) **Concentração da proteína no sangue vs expressão gênica**

2) Inflamação menos intensa, mas persistente

3) Remodelamento vascular e fibroses

4) Além dos sintomas identificados = formação de trombos (possível relação com SELP).

Fármaco = ANAKINRA




Conclusão

Pergunta de Pesquisa :

Quais proteínas atuam como nós centrais de alta influência (hub genes) na rede de interação de pacientes sintomáticos no estágio pós-COVID-19 ?



Hub genes **IL1B**, **SELP**, **PF4**, **ICAM1** e **EGF** são nós centrais na rede de pacientes pós-COVID-19.



Convergem para inflamação, disfunção endotelial e ativação plaquetária, associadas a sintomas como *brain fog*, fadiga e dispnéia.



Fármacos anti-inflamatórios, endoteliais e antiplaquetários podem modular esses *hubs* e reduzir a inflamação persistente.



A modulação integrada desses *hubs* pode restaurar a homeostase vascular e imunológica, melhorando a qualidade de vida dos pacientes.

References

J. Sun et al., "A multi-omics strategy to understand PASC through the RECOVER cohorts: a paradigm for a systems biology approach to the study of chronic conditions," *Front. Syst. Biol.*, vol. 4, p. 1422384, Jan. 2025, doi: 10.3389/fsysb.2024.1422384.

S. Pinero et al., "Integrative Multi-Omics Framework for Causal Gene Discovery in Long COVID," *PLoS Comput Biol*, Feb. 2025, doi: 10.1371/journal.pcbi.1013725.

M. Zoodsma et al., "Targeted proteomics identifies circulating biomarkers associated with active COVID-19 and post-COVID-19," *Front. Immunol.*, vol. 13, p. 1027122, Nov. 2022, doi: 10.3389/fimmu.2022.1027122.

Z. Liu et al., "Identification and evaluation of candidate COVID-19 critical genes and medicinal drugs related to plasma cells," *BMC Infectious Diseases*, vol. 24, p. 1099, 2024, doi: 10.1186/s12879-024-10000-3.

G. S. Carnivali, "Analisando características da rede genética gerada por genes vinculados ao Covid-19," *IAJMH*, vol. 3, pp. 1–7, Apr. 2020, doi: 10.31005/iajmh.v3i0.97.

G. S. Carnivali, "STUDY on the INTERACTIONS BETWEEN GENES LINKED to COVID-19 and GENES EXPRESSED in the HUMAN BODY," *J Proteomics Bioinform*, vol. 14, p. 254, Sep. 2021.

References

Stojanovic, Maja *et al.* **Vascular Complications of Long COVID—From Endothelial Dysfunction to Systemic Thrombosis: A Systematic Review.** [S. l.], 2025. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12786942/#sec3-ijms-27-00433>.

Nicolai, Leo *et al.* **Thromboinflammation in long COVID—the elusive key to postinfection sequelae?** [S. l.], 2023. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1538783623004002>.

Takamatsu, Naoki *et al.* **Persistent Interleukin-1 β Elevation in Post-COVID-19 Patients: Findings From a Nationwide Registry Study in Japan.** [S. l.], 2026. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12949360/>.

Moatar Alexandra *et al.* **HB-EGF Plasmatic Level Contributes to the Development of Early Risk Prediction Nomogram for Severe COVID-19 Cases.** [S. l.], 2024. Disponível em: <https://www.mdpi.com/2227-9059/12/2/373>.

Khani, Elnaz *et al.* **Current evidence on the use of anakinra in COVID-19.** [S. l.], 2022. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1567576922005598>. Acesso em: 7 jun. 2026.

Obrigado pela atenção!

Dúvidas?